

КЛАССИФИКАЦИЯ ВИДОВ ДЕРЕВЬЕВ НА ОСНОВЕ МАССИВОВ ТОЧЕК LiDAR С ПРИМЕНЕНИЕМ НЕЙРОННЫХ СЕТЕЙ


Студенты группы [REDACTED]:

Гречихин Илья Сергеевич


[REDACTED] Ольга [REDACTED]

Руководитель: [REDACTED]

г. Владивосток, 2026 г.



Цель и актуальность исследования




Цель исследования: адаптация и обучение алгоритмов машинного и глубокого обучения для автоматической классификации видов деревьев на основе трехмерных облаков точек лазерного сканирования.

Актуальность исследования: Мониторинг обширных и труднодоступных лесов – сложная, но важная задача. Традиционная наземная оценка лесов требует слишком много времени и человеческих ресурсов. Съемка с обычных камер или спутников также имеет ограничения: она показывает только верхнюю часть крон и не всегда позволяет точно определить породу дерева.

Цель и актуальность исследования

В связи с вышесказанным лесному хозяйству нужны новые методы. Эту проблему успешно решает технология лазерного сканирования LiDAR. Она создает детализированные трехмерные копии деревьев в виде облаков точек, которые повторяют уникальную форму стволов и ветвей.

Чтобы не анализировать такие огромные массивы 3D-данных вручную, в данной работе применяются современные нейронные сети. Они позволяют автоматизировать процесс и с высокой точностью распознавать виды деревьев, что необходимо для грамотного и оперативного управления лесными ресурсами.





Задачи исследования

Задачи:

- 1) Подготовить размеченную выборку облаков точек отдельных деревьев для выбранных видов.
- 2) Адаптировать и обучить модели классификации, опирающиеся как на классическое машинное обучение, так и на глубокие нейронные сети.
- 3) Сравнить результаты качества категоризации у различных нейросетевых моделей и выделить наиболее подходящую.

Объект исследования:

Трёхмерные массивы точек лазерного сканирования лесных массивов.

Предмет исследования:

Нейросетевые методы и архитектуры для классификации видов деревьев по трёхмерным облакам точек.


Особенности и ограничения LiDAR-данных

Специфика формата LAS/LAZ

Результатом сканирования является неструктурированное облако точек. Каждая точка описывается вектором атрибутов: координатами (X, Y, Z), интенсивностью, параметрами возврата и кодом классификации.

Фундаментальные ограничения:

- **Инвариантность:** точки не имеют порядка; алгоритм должен распознавать объект независимо от последовательности данных.
- **Неравномерность данных и «слепые зоны» :** плотность падает с расстоянием, а кроны создают «слепые зоны», нарушая целостность.
- **Отсутствие топологии:** нет явных связей; вычисление форм требует огромных затрат без индексации.
- **Масштаб и шум:** гигабайтные объемы содержат ложные отражения от атмосферы и птиц.



Методы классификации 3D-данных LiDAR

Сырое облако точек LiDAR

Классическое машинное обучение

SVM: Ищет идеальную математическую границу, чтобы разделить деревья разных пород друг от друга.

K-NN: Классифицирует объект на основе большинства голосов его ближайших соседей в наборе данных.

Random Forest: Ансамбль решающих деревьев, усредняющий прогнозы для повышения точности и стабильности.

Глубокое машинное обучение

Воксельные 3D CNN: Преобразовывают облако в регулярную сетку вокселей, применяя стандартные 3D-свертки.

Проекционные Multi-view CNN: Генерируют 2D-виды объекта с разных ракурсов для анализа обычной сверткой.

PointNet++: Прямая обработка сырых координат с иерархическим извлечением локальных признаков.


Базовая модель: Алгоритм «Случайный лес»

Принцип работы Random Forest


В качестве базовой модели был выбран алгоритм «Случайный лес» (Random Forest). Это классический и очень надежный метод.

Суть заключается в создании «комитета» из сотен независимых решающих деревьев. Алгоритм ищет оптимальные правила на основе входных параметров.

- Голосование: финальный ответ принимается большинством голосов всех деревьев.
- Прозрачность: метод быстрый и легко интерпретируемый.
- Пример: «Если высота > 15м и ветки внизу – это ель».



Глубокая нейронная сеть PointNet++



Принцип иерархического анализа

Противовесом Случайному лесу выступает нейронная сеть PointNet++. Вместо общих формул она использует принцип локального осмотра.

Сеть равномерно раскидывает «якоря» по всему дереву, захватывает ближайших соседей в сферы и изучает их переплетения.

- Сначала распознаются мелкие детали: кусочки коры и изгибы веток.
- Затем данные объединяются в макроструктуры: форму целой кроны.

Цель: сравнить математические признаки человека и скрытый анализ нейросети.

Исходные данные и их недостатки

Выбранные данные

Для исследования была использована база данных из шести пород деревьев: ель, сосна, пихта, береза, осина и ольха.

Исходные данные представляли собой «сырые» файлы, которые нельзя было сразу отдать компьютеру.

Во-первых, большинство деревьев были вырезаны из леса вместе с кусками земли, камнями и травой.

Во-вторых, у всех деревьев было разное количество точек (от двух до пяти тысяч).

Кроме того, они имели огромные географические координаты, что привело бы к ошибкам в математических расчетах сети.



Берёза



Сосна



Ель

Исходные данные и их недостатки

Исходные данные

Чтобы модели работали корректно, была написана программа очистки данных из трёх шагов.

Сначала скрипт отсекал нижние 40 сантиметров облака, полностью удаляя землю и оставляя только чистый ствол. Затем облако прореживалось. Все деревья были приведены к единому стандарту – ровно 2048 точек. Этого достаточно для сохранения формы кроны и не перегружает видеокарту.


В конце каждое дерево было смещено ровно в нулевой центр координат и сжато в невидимую сферу, сохранив идеальные пропорции. После этого данные были готовы к обучению.



Берёза




Сосна



Ель

Извлечение математических признаков

Чтобы научить «Случайный лес» различать деревья, объемные модели крон были превращены в набор понятных компьютеру чисел. Такой алгоритм детально сканирует структуру каждой кроны и вычисляет 17 уникальных характеристик, которые описывают её форму и плотность.



Извлечение математических признаков

Чтобы научить «Случайный лес» различать деревья, объемные модели крон были превращены в набор понятных компьютеру чисел. Такой алгоритм детально сканирует структуру каждой кроны и вычисляет 17 уникальных характеристик, которые описывают её форму и плотность.

Математические признаки

Плотность распределения по ярусам

3 признака. Высота делится на 3 равных яруса. Алгоритм вычисляет границы и долю точек в каждом слое.

Используется индикаторная функция для подсчета доли точек в интервалах высот.

$$Ratio_{bottom} = \frac{1}{N} \sum_{i=1}^N [Z_i < h_{33}]$$

Главные компоненты

3 признака. Описывают форму облака через собственные значения матрицы ковариации. Сортируются по убыванию ($\lambda_1 \geq \lambda_2 \geq \lambda_3$).

Позволяет математически отличить шар от плоской тарелки или вытянутого овала.

$$C = \frac{1}{N} \sum (P_i - \bar{P})(P_i - \bar{P})^T$$

Обучение модели Random Forest


Результаты обучения

Подготовленная таблица признаков, включающая 17 геометрических метрик, была загружена в модель Случайного леса.

Для обучения данные были разделены в пропорции 80/20. Была использована стратификация, чтобы сохранить исходное распределение пород: алгоритм учился на 80 процентах деревьев, а проверял себя на оставшихся 20.

Модель была сконфигурирована с 200 независимыми решающими деревьями. Обучение заняло всего пару секунд, так как алгоритм работал с легкими таблицами, а не с тяжелой 3D-графикой.

Базовая точность составила почти 80%, что является отличным стартовым результатом.




Принцип работы нейросети PointNet++

Как PointNet++ представляет дерево

Весь процесс работы нейросети можно разделить на четыре логических шага:

- Локальный анализ: Сеть получает облако из 2048 точек и выбирает 1024 опорных центра. Вокруг них строятся сферы. Координаты точек внутри сфер умножаются на обучаемые матрицы весов, превращаясь в 256 геометрических признаков. Затем операция Max Pooling выбирает самые яркие признаки и «схлопывает» каждую сферу в одну точку.
- Укрупнение масштаба: Из 1024 точек алгоритм выбирает 256 новых центров. Радиус сфер увеличивается – теперь сеть смотрит на целые ветви. Признаки расширяются до 512, и снова применяется Max Pooling.
- Цифровой слепок: Вся информация от оставшихся 256 кусков кроны сливается в единый вектор из 512 чисел. Финальные слои сжимают это представление дерева до шести процентов вероятности (для каждой породы).
- Обучение: Сделав предсказание, сеть проверяет правильный ответ. Если она ошиблась, алгоритм делает шаг назад и чуть-чуть подправляет числа во всех матрицах весов, чтобы в следующий раз ответить точнее



Аугментация данных



Оригинал



Поворот



Шум



Поворот +
Шум

Борьба с переобучением PointNet++

Главный враг глубоких нейросетей – это переобучение. Если показывать программе одни и те же идеальные деревья, она просто запомнит их наизусть, но ошибется в реальном лесу.

Для комплексного решения этой проблемы было применено два метода. Первый – динамическое искажение данных. Прямо во время обучения программа случайным образом вращала деревья вокруг своей оси и добавляла легкий шум к координатам, имитируя погрешность лазерного сканера. В итоге сеть видела каждое дерево с сотен разных ракурсов и училась понимать истинную форму кроны.


Второй метод – функция Dropout, встроенная в саму архитектуру сети. Во время обучения этот алгоритм временно и случайным образом «отключал» 50% связей между нейронами в финальном классификаторе. Сеть заставляли распознавать березу или ель, опираясь лишь на половину доступной информации. Такой подход не дает алгоритму привыкнуть к конкретным признакам и делает модель максимально надежной на новых данных.

Процесс обучения нейросети

Обучение PointNet++

Обучение нейросети проходило на графическом процессоре и заняло сто циклов (эпох). Процесс контролировался в режиме реального времени, что позволило нам следить за отсутствием переобучения. На графиках видно классическое правильное поведение: линия ошибки стремительно падает, а точность распознавания растет и фиксируется на высоком уровне.

Чтобы достичь максимум точности, был использован умный планировщик шага обучения (Scheduler). Когда программа замечала, что точность на проверочной выборке перестает расти, она плавно уменьшала learning rate в два раза. Это позволило алгоритму перейти от грубой корректировки весов к аккуратной настройке параметров на финальных этапах. Стратегия сохранения гарантировала, что на жесткий диск была записана именно та версия весов сети, которая показала наилучший исторический результат на чистых данных.



Финальный тест моделей


Отложенная выборка

Для объективного сравнения алгоритмов были отобраны 24 контрольных дерева – по 4 экземпляра каждого вида. Эти данные не использовались на этапе обучения.

В процессе тренировки каждое облако точек динамически сжималось или расширялось до 2048 единиц через случайную выборку.

Чтобы провести объективное финальное тестирование, над каждым отложенным деревом были проведены следующие трансформации: оно стократно поворачивалось под произвольным углом, и каждый раз заново проходило через алгоритм разрежения.

Суммарно модели выполнили 2400 предсказаний. Такая нагрузка имитирует реальные условия эксплуатации, когда беспилотник приближается к объекту в лесу с любого произвольного ракурса.



Финальный тест моделей

Матрица ошибок: Случайный лес

Здесь видна матрица ошибок классического алгоритма.

Тёмная диагональ означает правильные ответы, и видно, что базовая математическая модель неплохо справилась со своей задачей.


Она уверенно распознает ольху и сосну. Однако есть явная проблема с лиственными породами. Из 400 попыток алгоритм угадал березу лишь в половине случаев. Остальные деревья он перепутал с осиной или сосной.

Это происходит потому, что классическая статистика описывает лишь общие контуры дерева. У березы и осины очень похожая округлая форма кроны, поэтому их числовые показатели сливаются, и алгоритм начинает сомневаться и принимать решения наугад.

Random Forest (Acc: 82.1%)

Истинный класс \ Предсказание модели	Alder	Aspen	Birch	Fir	Pine	Spruce
Alder	318	21	61	0	0	0
Aspen	2	390	7	0	1	0
Birch	0	100	199	0	100	1
Fir	0	0	0	308	0	92
Pine	0	2	30	0	368	0
Spruce	0	0	0	13	0	387

Логика принятия решений Random Forest



Важность признаков

Несмотря на ошибки, у классического машинного обучения есть огромное преимущество: абсолютная прозрачность. Нам точно известно, как машина думает.

График важности признаков показывает, что самым ценным параметром стала густота веток в средней части ствола. Именно этот показатель позволяет легко отделить пушистые хвойные деревья от лиственных, у которых середина ствола часто голая.

На втором месте оказались показатели вертикального профиля, то есть высота, на которой растет основная масса веток.

А вот простой разброс точек в пространстве оказался бесполезным. Машине важно понимать именно структуру дерева по высоте, а не просто его ширину.

Финальный тест моделей

PointNet++ (Acc: 92.3%)

Истинный класс \ Предсказание модели	Alder	Aspen	Birch	Fir	Pine	Spruce
Alder	377	0	20	0	3	0
Aspen	0	341	45	0	7	7
Birch	23	9	364	0	4	0
Fir	0	0	0	396	0	4
Pine	0	0	31	0	369	0
Spruce	0	0	0	31	0	369

Матрица ошибок: PointNet++

Матрица ошибок глубокой нейросети выглядит совершенно иначе. Темная линия правильных ответов здесь гораздо плотнее, а путаница между породами практически исчезла.

PointNet++ продемонстрировал впечатляющую стабильность. Нейросеть успешно разделила все хвойные породы, не допуская путаницы между елью, пихтой и сосной. Она сфокусировалась на истинной трехмерной структуре веток, а не на простых габаритах кроны.

Ошибки остались только в самых сложных биологических случаях, когда сеть изредка путает березу с осинкой. Однако даже в этой трудной ситуации общее количество промахов оказалось в разы меньше, чем у математической модели.

Финальный тест моделей


Итоговое сравнение

Финальная диаграмма подводит объективный итог нашего масштабного тестирования. На ней наглядно видно абсолютное превосходство глубокого обучения по всем ключевым параметрам.

Общая точность PointNet++ в условиях постоянного вращения объектов уверенно превысила 92%, обойдя базовую модель, общая точность которой достигла 82%.

Особенно важен показатель полноты, который вырос на три процента. Это значит, что нейросеть научилась находить нужные деревья без пропусков.

Главный показатель качества, который учитывает баланс всех ошибок, подтверждает: глубокое обучение способно выучивать истинную форму объектов. Нейросеть работает гораздо стабильнее ручных математических формул.



Заключение

Итоговый вывод

Исследование на практике доказало, что классические методы машинного обучения достигли своего предела в задачах сложного трехмерного анализа. Наглядно видно, что ручное конструирование математических признаков хорошо работает в базовых тепличных сценариях, но неизбежно дает сбой при столкновении со схожими по форме объектами в реалистичных условиях леса.

Архитектура PointNet++ оказалась наиболее точным и надежным инструментом для распознавания сложной природной геометрии. Способность алгоритма самостоятельно находить скрытые узоры ветвей прямо в «сыром» массиве точек делает модель абсолютно устойчивой к пространственным искажениям, смене ракурсов и погрешностям сканирования. Нейросеть успешно преодолела ограничения классической математики, снизив процент ошибок даже в биологически родственных классах.

Все это делает технологию глубокого обучения идеальным кандидатом для внедрения в реальный сектор лесного хозяйства. В перспективе разработанный подход можно масштабировать. Если объединить текущую модель классификации с алгоритмами сегментации, которые могут автоматически находить и «вырезать» границы отдельных крон в сплошном массиве данных, мы получим полностью автономную программную систему для оперативной инвентаризации и мониторинга лесных ресурсов.